

Корпоративная платформа хранения и обработки больших данных

Arenadata DB для Разработчиков

Часть 1



ADB – аналитическая СУБД для больших данных

Введение в ADB:

Назначение ADB. Отличия от других систем. Отличия от GP.

Обзор архитектуры ADB:

Концепция MPP и её имплементация в ADB. Терминология и архитектура СУБД.

Окружение СУБД:

Кластер-менеджер ADCM. Мониторинг. Enterprise Tools.

Подключение к БД:

Реквизиты. Клиент командной строки. Графические клиенты.

Устройство БД:

Шаблоны БД. Логическая схема данных. Обзор дефолтных схем. Основные объекты для работы с БД.

Ролевая модель:

Роль и пользователь, группы. Доступы. Создание пользователей, управление.

Ресурсные группы:

Параметры и ограничения. Создание ресурсных групп.

Дисковая квота:

Информация о модуле. Настройка. Нюансы использования.





Корпоративная платформа хранения и обработки больших данных

Введение в ADB



ADB – аналитическая СУБД для больших данных

Основные сведения о системе:

- Arenadata DB (ADB) SQL-совместимая реляционная аналитическая СУБД, построенная на основе MPP-системы с открытым исходным кодом Greenplum.
- Основное назначение выполнение сложных запросов аналитического профиля (OLAP)
 с большими объёмами структурированных данных.
- В качестве инфраструктуры для размещения ADB используются кластеры, которые могут включать до сотен серверов.



ADB – GP с дополнительной функциональностью

Arenadata DB имеет ряд преимуществ перед ванильным Greenplum:

- Arenadata Cluster Manager инструмент, значительно упрощающий установку и настройку СУБД, в том числе в закрытых ЦОДах без доступа в интернет.
- Нативная интеграция с Arenadata Hadoop, QuickMarts (ClickHouse), Streaming (Kafka&NiFi) в рамках единой платформы Arenadata EDP и другие дополнительные возможности интеграции.
- Система мониторинга и оповещения (Graphite и Grafana).
- Arenadata Command Center инструмент для работы с запросами. Он дает рекомендации по улучшению запросов и прогнозы времени работы.
- Поддержка x86 и Power-совместимого оборудования (8, 9, OpenPower).



Ванильный GP и ADB Community/Enterprise Edition

Функционал	Open Source дистрибутив	ADB CE	ADB EE
 Core-функционал PXF gpbackup Коннекторы Greenplum <-> Hadoop и Greenplum <-> JDBC-источники 	+	+	+
• Коннекторы Greenplum <-> Kafka и Greenplum -> ClickHouse	-	-	+
 Command Center (мониторинг на уровне запросов) оффлайн установка 	-	-	+
 Управление деплоем и апгрейдом, Расширение кластера, Мониторинг & alerting 	-	+	+
• Client/Loader утилиты	-	-	Redhat 8
• Документация	English only	+	+
ПоддержкаОбучение по продуктам	-	-	+
• Операционная система	Ubuntu 18.04/ Redhat 7 / Redhat 6	CentOS 7/ Redhat 7	CentOS 7 / Redhat 7/ Альт 8 СП Сервер
• Доп.консалтинговые услуги (DBAaS, Smart Start, TAM, Аудит)	-	-	+



Системы для больших данных: сравнение

Hadoop (ADH)

Роль:

- Подходит для хранения и обработки сырых и агрегированных данных.
- Служит как хранилище для холодных данных.

Плюсы:

 Анализ данных с помощью популярных фреймворков, например Spark, PySpark.

Минусы:

- Трудоёмко писать задачи MapReduce.
- Медленнее, чем GP и ClickHouse.

Greenplum (ADB)

Роль:

 Подходит для КХД, так как может хранить и обрабатывать данные из разных слоёв.

Плюсы:

- Настоящая МРР-система.
- Совместим с ANSI SQL 2008.
- Postgres-совместим. Могут быть подключены типовые BI и ETL системы.
- Транзакционный.
- Локальные и распределенные джойны.
- Хорошо справляется с ELT (ETL с интеграцией слоёв данных для КХД).

ClickHouse (ADQM)

Роль:

 Выдача готовых данных большому числу пользователей. Подходит для быстрых запросов к широким таблица фактов и к витринам.

Плюсы:

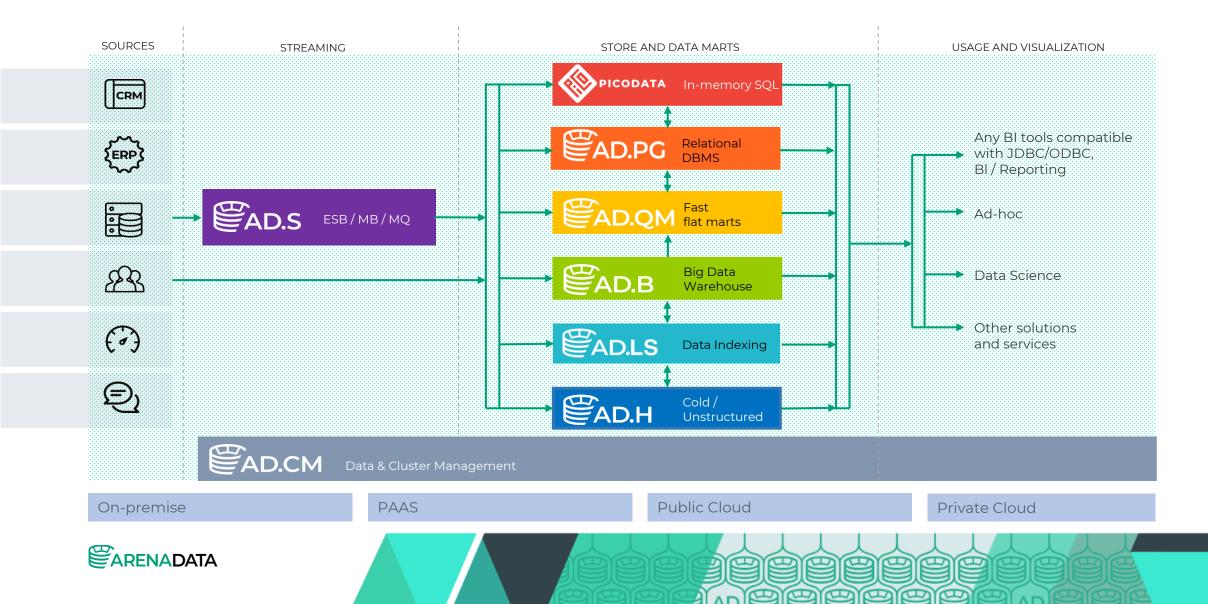
- Очень быстро работает с whereусловиями и строит агрегаты очень быстро.
- Позволяет гибко задавать логические схемы шардирования и зеркалирования.

Минусы:

- Сложности с джойнами.
- Нет транзакций.
- Несколько сложен в настройке и эксплуатации.



Arenadata Enterprise Data Platform





Корпоративная платформа хранения и обработки больших данных

Архитектура кластера ADB

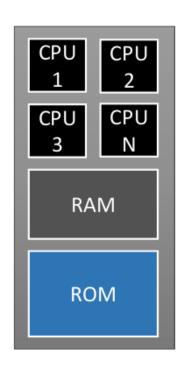
Обзор архитектуры: SMP и MPP

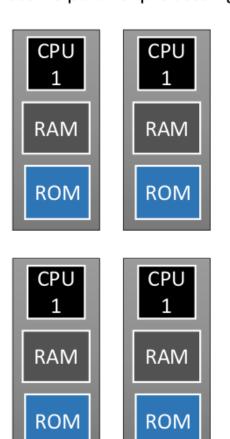
SMP (symmetric multiprocessing)

MPP (massive parallel processing)

Преимущества МРР-систем:

- Горизонтальная масштабируемость.
- Линейный рост производительности.
- Большие возможности расширения.
- Отказоустойчивость.



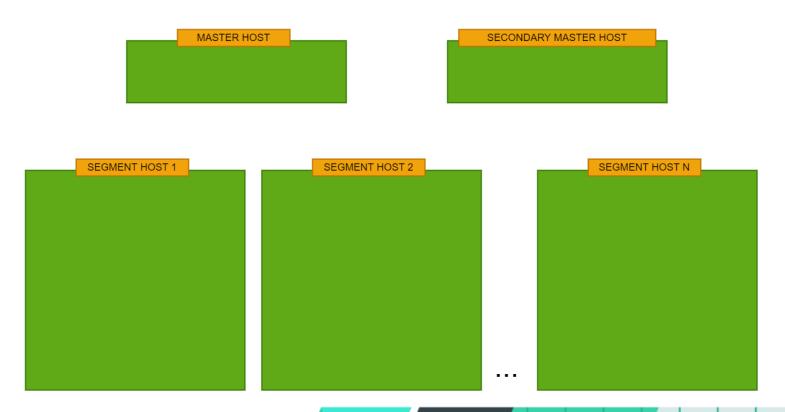




Структура кластера ADB: серверы

Кластер ADB разворачивается на наборе машин, состоящем из:

- Одного мастер-сервера master host и (опционально) одного запасного мастер-сервера secondary master.
- Не менее двух одинаковых сегментных серверов segment host.



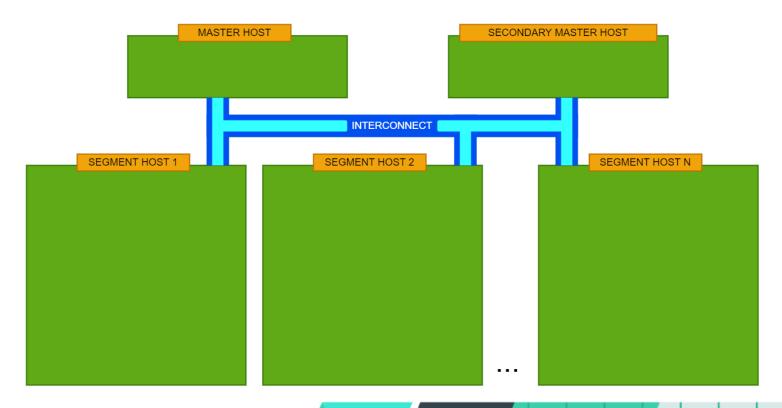
- Сегментные серверы должны быть одинаковыми по характеристикам.
- Мастер-сервер обычно делают вдвое слабее сегментного.
- При выборе из малого числа мощных машин и большого числа, но слабее, обычно лучше второй вариант.
- Количество сегментных серверов можно увеличить (расширить кластер), но нельзя уменьшить.



Структура кластера ADB: интерконнект

Машины соединяются между собой сетью-интерконнектом:

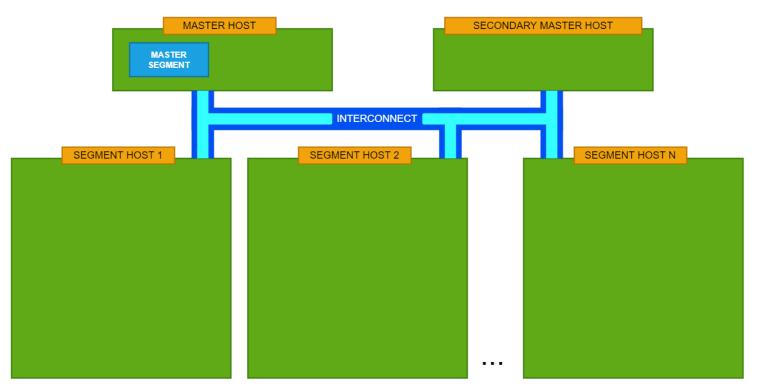
- Не менее 10 Гигабит. Как правило, в типовых конфигурациях используют 2х40 или 1х100.
- По умолчанию ADB использует UDP (своя реализация TCP over UDP), можно переключить на обычный TCP.





Мастер-сервер и мастер-сегмент:

- Мастер-сервер является единой точкой входа для работы с СУБД.
- На мастер-сервере размещается одна копия СУБД Postgres, именуемая *мастер-сегментом*. Слушает порт 5432.



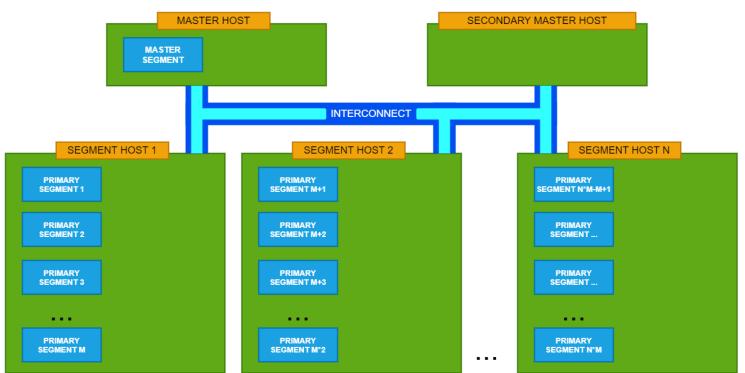
- Мастер-сегмент не хранит содержимого пользовательских объектов.
- На мастере хранятся данные системного каталога.
- Мастер может выполнять некоторые финальные операции с данными агрегации, сортировки и т.д..
- Большинство административных действий выполняются только на мастере.



Праймари-сегменты на сегментных хостах:

На каждом сегментном сервере присутствует одинаковое число копий СУБД Postgres - праймари-сегментов.
 Типовая конфигурация – 1 сегмент на каждые 2 ядра процессора сегментного сервера.

• Каждый сегмент хранит свою отдельную часть от общего набора данных.

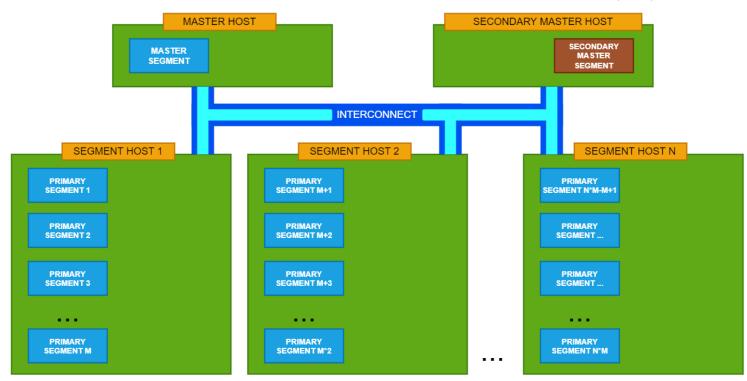


- Любая таблица в БД распределяет свои данные сразу по всем праймари-сегментам.
- Каждый праймари-сегмент имеет копию системного каталога с мастера.
- Большинство действий, связанных с обработкой данных, выполняется локально на сегментах.
- Сегменты обмениваются данными между собой по интерконнекту во время выполнения запроса.



Вторичный мастер и его сегмент:

- На запасной машине размещается одна копия Postgres, которая является зеркальной копией мастер-сегмента.
- Вторичный мастер-сегмент не выполняет никаких действий, кроме резервного копирования данных мастерсегмента. При сбое на мастер-сервере администратор вручную назначает вторичному серверу роль мастера.

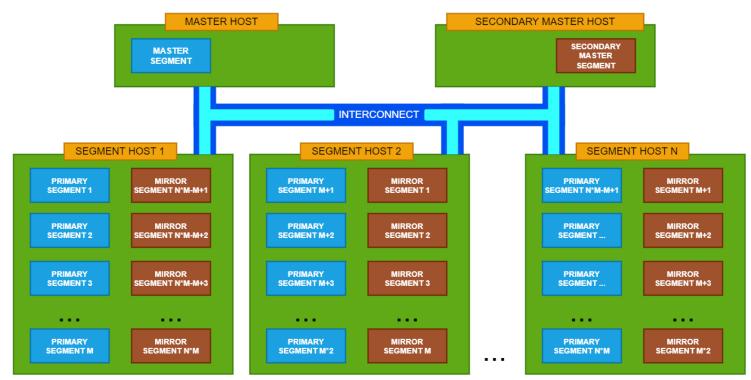




Зеркала праймари-сегментов:

- У каждого праймари-сегмента по умолчанию есть одно (больше нельзя) зеркало на другом сервере кластера.
- Зеркала служат только для резервного копирования данных, включаясь в основную работу только при сбое в праймари-сегменте. Переключение на зеркало происходит автоматически, обратное вручную.

B





Структура кластера ADB: отказоустойчивость

Отказоустойчивость мастера:

- Warm standby (реплика каталога).
- Синхронная репликация на основе WAL.
- Автоматического переключения при сбое нет, необходимо сделать это вручную.

Отказоустойчивость сегментов:

- Для каждого основного сегмента создаётся зеркало.
- Синхронная репликация на основе WAL.
- Автоматическое переключение при сбое.
- Для обратного переключения нужно выполнить процедуру восстановления.
- Есть два варианта расположения зеркал. Один из них выбирается на этапе установки СУБД.



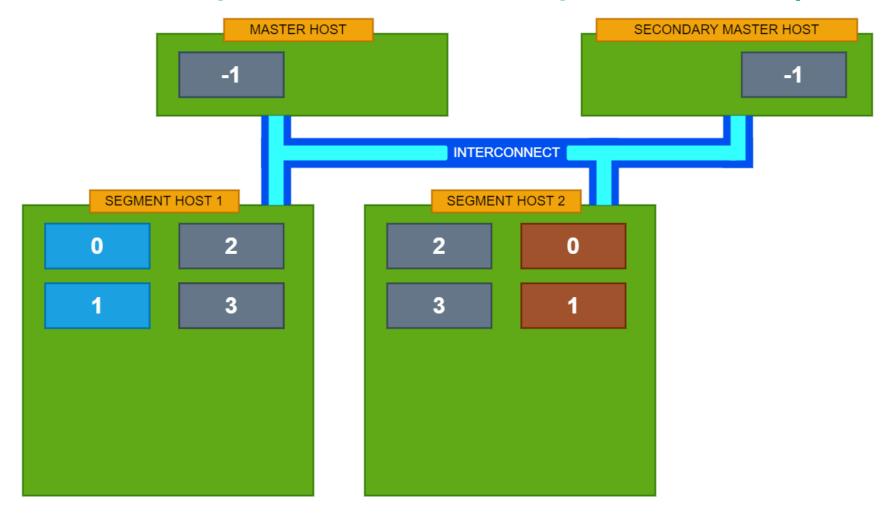
Политики размещения зеркал: Group mirroring

В ADB зеркала могут размещаться двумя отдельными способами. Первый способ – это размещение группами (Group mirroring):

- Все зеркала для основных сегментов, находящихся на одном физическом сервере, вместе размещаются на каком-то другом.
- Выходит, что один сервер целиком страхует другой и возьмет на себя всю его нагрузку в случае выхода того из строя.
- При выходе из строя одного сегментного сервера скорость работы кластера сразу замедляется вдвое.
- Конфигурация возможна при любом соотношении количества сегментных серверов и количества сегментов на одном сервере, но в ADB при возможности автоматически выбирается другой вариант размещения зеркал.



Политики размещения зеркал: Group mirroring





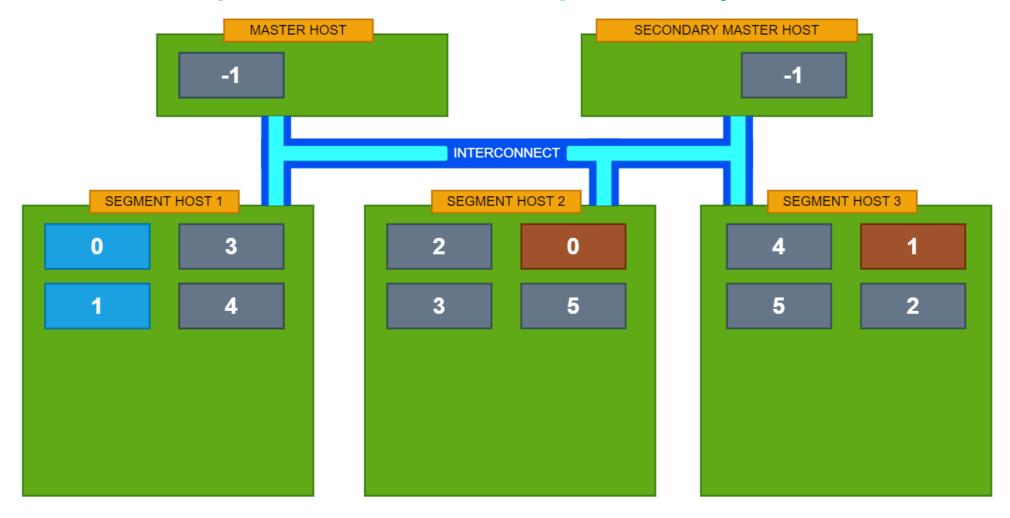
Политики размещения зеркал: Spread mirroring

Второй вариант – это распределенное размещение (Spread mirroring):

- Зеркала праймари-сегментов с одного сегментного сервера попадают на разные сегментные серверы (по одному на сервер). Для этого число сегментных серверов должно как минимум на единицу превышать число сегментов на сервере.
- При выходе из строя одного сегментного сервера скорость работы кластера падает не столь значительно, чем при Group mirroring, так как возросшая нагрузка распределяется между набором серверов.
- Уязвимость к повторному сбою при Spread mirroring выше. В случае с Group Miroring при выходе из строя сервера к отказу системы может привести поломка одной машины на которой лежат зеркала уже упавшей. Падение других условно безопасно.
- При Spread mirroring система откажет при падении любой из машин, на которые были распределены зеркала.



Политики размещения зеркал: Spread mirroring





Структура кластера ADB: резюме

- Кластер в норме состоит из управляющей машины (мастер-сервер) и набора одинаковых по характеристикам серверов для хранения и обработки данных (сегментные хосты).
- У мастер-сервера может быть резервная замена вторичный мастер-сервер. Все машины соединены интерконнектом с пропускной способностью не менее 10 гигабит.
- На машинах размещены отдельные экземпляры СУБД Postgres, именуемые сегментами.
- На мастер-сервере присутствует только один сегмент. На сегментных серверах один или более основных (праймари), а также зеркала сегментов с других серверов.
- Конфигурирование СУБД и подключение пользователей к базам выполняется на мастер-сервере. Основную работу с данными базы выполняется на праймари-сегментах сегментных серверов, мастер агрегирует их результаты и отдает пользователю результат выполнения запроса.
- Сегменты бывают основные и зеркальные. Зеркальные сегменты не отдают данные по запросу, на них выполняется только запись.
- Есть две политики зеркалирования: групповая и распределенная. Политика определяет то, как размещаются зеркала основных сегментов на сегментных серверах. Зеркало мастер-сегмента всегда находится на отдельном сервере.
- Переключение на зеркало мастера при сбое производится вручную. Переключение на зеркало при сбое рабочего сегмента происходит автоматически.





Корпоративная платформа хранения и обработки больших данных

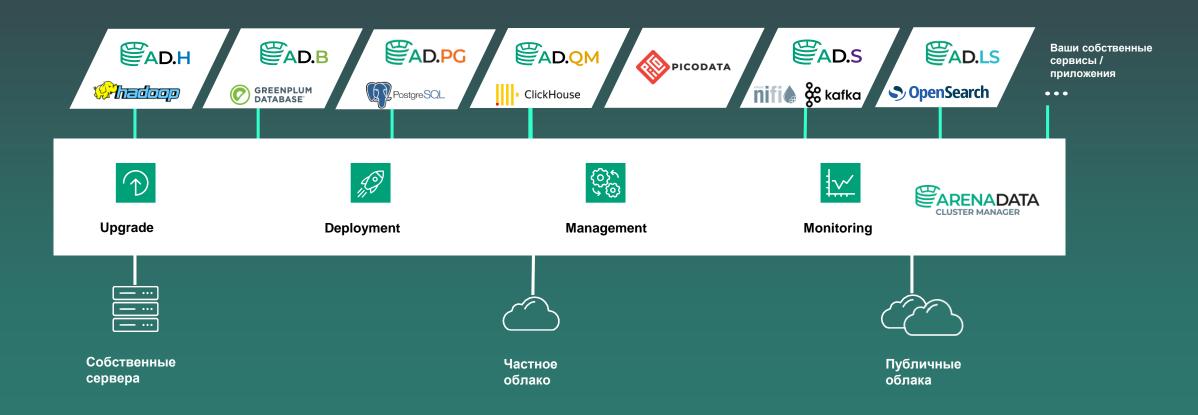
Кластер-менеджер ADCM

ADCM – система развертывания и управления

- Автоматизацию процессов обновления и управления обеспечивает Arenadata Cluster Manager
 (ADCM) отдельный разработанный продукт с открытым исходным кодом.
- ADCM это универсальный оркестратор гибридного ИТ-ландшафта, благодаря которому в автоматическом режиме происходят установка, настройка и обновление кластеров, настройки операционной системы, сервисов, сети и монтирование дисков.
- С помощью ADCM можно разворачивать data-сервисы как в облаке, так и on-premise, а также она может служить в качестве PaaS-сервисов.



ADCM – система развертывания и управления





ADCM – возможности

Уровень Data Service:

- Установка.
- Обновление.
- Управление.
- Мониторинг.
- Управление доступом.
- Интеграция между Data Service.

Уровень Infrastructure:

- Создание и удаление виртуальных машин.
- Настройка OS.
- Мониторинг.
- Управление пользователями.
- Управление доступом.

Присутствует Rest API, библиотеки для Python, модули и плагины Ansible для автоматизации.

Возможно создавать свои бандлы для расширения функциональности.



ADCM – бандлы

- ADCM bundle это специальный архивный файл, который содержит файлы конфигураций сервисов и Ansible-скрипты по управлению ими.
- Существует два типа бандлов: Cluster Bundle и Infrastructure Bundle.
- Cluster Bundle необходим для развертывания кластеров систем, в то время как Infrastructure Bundle позволяет добавить поддержку различных хост-провайдеров (таких как Google Cloud, Yandex Cloud или обычный ssh-хост).

Для ADB Community понадобятся: инфраструктурный бандл хоста (SSH в нашем случае), бандл ADB и бандл мониторинга.

Для ADB Enterprise потребуется дополнительно бандл Enterprise Tools.



ADCM как прикладное ПО

- Устанавливается в виде Docker-контейнера. Резервное копирование при этом бекап файловой системы.
- Достаточно одной инсталляции ADCM для всех дата-сервисов. Не следует размещать ADCM на сервере, который будет входить в состав системы, предоставляющей дата-сервис. При необходимости можно совмещать с системой мониторинга.
- Поддерживаемые ОС: CentOS 7/RHEL 7 (также возможна установка на Alt Linux 8.2).
- Для установки необходим доступ к репозиториям ОС (для CentOS CentOS Extras и CentOS Base).
- Перед установкой необходимо отключить SELinux.
- Пакеты, необходимые для установки:
 - o yum-utils.
 - o docker.
 - device-mapper-persistent-data.
 - o 1vm2.
- После установки консоль ADCM доступна по порту 8000.



Установка ADCM

На машине, куда ставится ADCM, следует выполнить последовательно команды:

- sudo sed -i 's/SELINUX=enforcing/SELINUX=disabled/g' /etc/selinux/config
- 2. sudo setenforce 0
- 3. sudo yum install -y yum-utils docker device-mapper-persistent-data lvm2
- 4. sudo systemctl enable docker --now
- 5. sudo docker pull arenadata/adcm:latest
- 6. sudo docker create --name adcm --restart unless-stopped -p 8000:8000 -v /opt/adcm:/adcm/data arenadata/adcm:latest
- 7. sudo docker start adcm

Интерфейс ADCM будет доступен в браузере по адресу http://<адрес машины>:8000 (ip-адрес машины adcm, порт 8000) с логином и паролем admin.



Обновление ADCM

На машине, где развернут ADCM, следует выполнить последовательно команды:

- 1. sudo docker stop adcm
- 2. sudo docker rm adcm
- 3. sudo docker pull arenadata/adcm:latest
- 4. sudo docker create --name adcm --restart unless-stopped -p 8000:8000 -v /opt/adcm:/adcm/data arenadata/adcm:latest
- 5. sudo docker start adcm

Интерфейс обновленной версии ADCM будет доступен в браузере по адресу http://<адрес машины>:8000 (ip-адрес машины adcm, порт 8000) с логином и паролем admin.



Лабораторная работа. Обновление ADCM

- 1. Откройте веб-интерфейс своего сервера ADCM и проверьте версию.
- 2. Подключитесь по SSH к этому серверу.
- 3. Выполните обновление.
- 4. Откройте веб-интерфейс и проверьте версию системы.

Логин и пароль для SSH-подключения и входа в веб-интерфейс одинаковые.





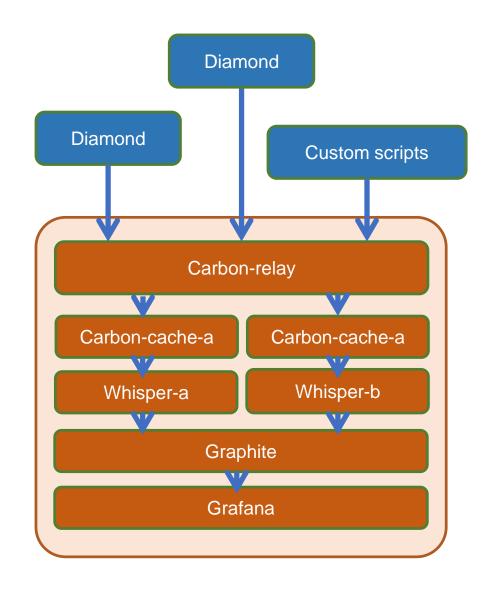
Корпоративная платформа хранения и обработки больших данных

Мониторинг в ADCM



Мониторинг

- Сервис мониторинга модульный, состоит из нескольких компонент:
 - Diamond собирает и отправляет системные метрики с серверов.
 - Carbon-relay принимает метрики, преобразует в бинарный формат и отправляет Carbon-caches.
 - Carbon-caches принимают метрики и записывают их в Whisper DB.
 - Whisper DB файловая временная БД.
 - Graphite фронтенд, читающий метрики из Whisper DB и отдающий их в ответ на особые запросы.
 - Grafana визуализатор метрик Graphite и алерты.
- Модульность системы позволяет выполнять масштабирование при росте числа метрик.





Мониторинг: Diamond

- Сервис: diamond.
- Работает под root, так как обращается к низкоуровневым метрикам.
- Установлен на всех серверах кластера.
- /var/log/diamond/archive.log архив всех отосланных метрик.
- /var/log/diamond/diamond.log ошибки и другие сообщения.
- /etc/diamond/diamond.conf настройка адреса отсылки, периодичности и т.д..
- Diamond имеет модульную архитектуру, расширяется благодаря коллекторам:



Мониторинг: Carbon

Сервисы: carbon-relay, carbon-cache-a, carbon-cache-b

Размещаются на сервере мониторинга внутри docker-контейнера graphite.

Логи:

- /var/log/carbon-relay.log логи сервиса carbon-relay (директория внутри контейнера).
- /var/log/carbon.log логи сервиса carbon-cache (директория внутри контейнера).

Конфигурационный файл:

• /etc/graphite/carbon.conf - секция relay, cache:a и сасhe:b. Размещается на сервере мониторинга.



Мониторинг: Wishper

• Просто директории в файловой системе сервера мониторинга:

- Файлы с метриками имеют расширение .wsp
- Точки в названии метрики преобразуются в структуру каталогов:

 Database.hardware.iops.sdw1 => Database/hardware/iops/sdw1.wsp
- Удаление файлов = удаление метрик.

Мониторинг: Graphite

- Устанавливается в виде docker-контейнера graphite.
- Конфигурационные файлы вынесены наружу в файловую систему сервера: /etc/graphite/.
- Приложение HTTP, сервис httpd.
- Интерфейс доступен на порту 80.
- Логин и пароль root.
- /opt/graphite/webapp/graphite/local_settings.py:

```
DATA_DIRS = ['/opt/graphite/whisper_a','/opt/graphite/whisper_b'].
```

• Можно использовать как источник данных для Zabbix.



Мониторинг: Grafana

- Устанавливается в виде docker-контейнера grafana.
- Конфигурационные файлы вынесены наружу в файловую систему сервера: /var/lib/docker/volumes/
 - grafana_data.
 - grafana_etc.
 - grafana_log.
- Интерфейс доступен на порту 3000.
- Логин и пароль задаются при установке.



Установка мониторинга (community)

- Откройте в браузере интерфейс ADCM (ір машины adcm, порт 8000) и войдите в систему.
- Создайте хост с названием monitoring и установите на него statuschecker.
- В настройках хоста укажите логин, пароль (или ключ) и IP-адрес.
- Загрузите бандл мониторинга.
- Создайте кластер с названием Monitoring Cluster на основе бандла мониторинга.
- Добавьте в кластер сервисы Graphite и Grafana.
- Укажите пароль в настройках сервиса Grafana.
- Добавьте хост monitoring в кластер.
- Установите добавленный хост как место размещения обоих сервисов.
- Запустите процесс установки кластера и проконтролируйте его до успешного завершения.
- Откройте в браузере интерфейс Grafana (ір машины, порт 3000) и войдите в систему с логином и паролем, заданными при установке.



Установка мониторинга (enterprise)

- Откройте в браузере интерфейс ADCM (ір машины adcm, порт 8000) и войдите в систему.
- У вас должен быть создан кластер Enterprise Tools на основе соответствующего бандла.
- Создайте хост с названием monitoring. В настройках хоста укажите логин, пароль (или ключ) и IP-адрес.
- Установите на него statuschecker.
- Добавьте в кластере Enterprise Tools сервисы Graphite и Grafana.
- Укажите пароль в настройках сервиса Grafana.
- Добавьте хост monitoring в кластер.
- Установите добавленный хост как место размещения обоих сервисов.
- Запустите процесс установки мониторинга в кластере Enterprise Tools и проконтролируйте его до успешного завершения.
- Откройте в браузере интерфейс Grafana (ір машины, порт 3000) и войдите в систему с логином и паролем, заданными при установке.





Корпоративная платформа хранения и обработки больших данных

Enterprise Tools



Инструментарий Enterprise Tools

Если согласно политике информационной безопасности доступ к ресурсам в нешним ресурсам ограничивается и требуется офлайн-установка, необходим инструментарий Arenadata Enterprise Tools.

Он позволяет создать локально инфраструктуру для развертывания продуктов Arenadata в закрытом контуре. Развертывание репозиториев выполняется из офлайн-пака, который поставляется с ADB Enterprise.

В состав входят:

- Docker registry. для организации офлайн-установки.
- HTTP Mirror. для организации офлайн-установки.
- Сервисы мониторинга. отдельный бандл мониторинга для ADB Enterprise не нужен.
- CoreDNS.



Обновление ADB

- 1. Откройте веб-интерфейс своего сервера ADCM.
- 2. Загрузите бандл enterprise tools.
- 3. Создайте хост с ip-адресом, логином и паролем сервера adcm.
- 4. Создайте кластер enterprise tools.
- 5. Добавьте в кластер сервисы http mirror и docker registry.
- 6. Добавьте в кластер созданный хост.
- 7. Разместите сервисы на хосте.
- 8. Запустите установку (не офлайн).
- 9. Дождитесь окончания установки и запустите задачу upload pack.
- 10. Запустите процесс удаления расширения GPPerfmon в ADB и дождитесь его завершения.
- 11. Переведите кластер ADB в режим обновления.
- 12. Выполните импорт Docker Registry и HTTP Mirror в кластере ADB.
- 13. Запустите процесс обновления и проконтролируйте его до успешного завершения.
- 14.Добавьте сервис ADBCC, разместите его на хосте mdw и запустите процесс установки.





Корпоративная платформа хранения и обработки больших данных

Подключение к СУБД



Работа в ADB: консольный клиент psql

В стандартной поставке ADB присутствует консольный клиент psql. Им можно подключиться к базе, вызвав его по названию в командной строке и передав параметры через ключи:

- 1. h адрес мастер-сервера.
- -р порт СУБД.
- 3. d название БД.
- 4. U имя пользователя.

При этом:

- 1. При запуске утилиты непосредственно на мастер-сервере адрес можно не указывать.
- 2. Порт тоже можно не указывать, будет взят PGPORT.
- 3. Имя БД нужно обязательно. Если это единственный параметр, ключ -d не нужен, достаточно названия.
- 4. Если не указать имя пользователя, будет взят пользователь ОС.

T.e. для работы на учебном кластере достаточно перейти под пользователя gpadmin командой sudo su – gpadmin и вызвать клиент с указанием имени БД командой psql adb.



Работа в ADB: консольный клиент psql

При работе с консольным клиентом могут пригодится следующие команды:

- 1. -с 'sql query' выполнить SQL-запрос и завершить сессию.
- 2. -f filename выполнить запрос из файла и завершить сессию.
- 3. Использование в скриптах: psql -d adb -Atc 'select * from pg_class'.
- 4. \? справочник по внутренним командам psql.
- 5. \q закрыть подключение к СУБД.
- 6. \d+ вывести подробное описание объекта (таблицы или представления).
- 8. \timing включить отображение времени выполнения запроса.

При этом следует помнить, что:

- Запросы завершаются точкой с запятой.
- Точка с запятой после ввода специальной команды клиента команды не требуется.



Лабораторная. Подключение к ADB

Подключитесь к БД при помощи консольного клиента.

Для учебного кластера:

- 1. Адрес мастер-сервера у каждого свой. Правильно определите IP-адрес мастера в описании.
- 2. Порт был в материале ранее.
- 3. Название БД: adb.
- 4. Имя пользователя: gpadmin.
- 5. Пароль: *пароля у пользователя gpadmin в нашем случае нет.*

Проверьте возможность выполнения запроса с использованием объекта в служебной схеме.

Следующий запрос должен выполниться: select rsgname from gp_toolkit.gp_resgroup_status;

- Выполните запрос: select * from pg_catalog.pg_class where relname = 'pg_class';
- Просмотрите информацию о структуре таблицы pg_catalog.pg_class.
- Просмотрите информацию о структуре таблицы gp_toolkit.__gp_log_master_ext.





Корпоративная платформа хранения и обработки больших данных

Обзор системы



Директории с настройками и данными

- Macтep-ceгмент: /data1/master/gpseg-1
- Основные сегменты: /data<disk>/primary/gpseg<contentid>/

В них будут директории и файлы:

• base – директория с файлами таблиц filespace pg_system. Внутри данные в директориях вида:

```
<db1 oid>/<table1 oid>
<db2 oid>/<table1 oid>
```

- db_analyze директория с информацией работы утилиты analyzedb (только на мастере, может переполниться, следите).
- global директория с файлами global-таблиц.
- gpperfmon логи, конфиги и т.д. Gpperfmon (только на мастере).
- gpssh.conf тонкие настройки gpssh.
- pg_clog журналы метаданных транзакций.
- pg_distributedlog файлы синхронизации *основной сегмент -> зеркало*.
- pg_hba.conf настройки доступа к БД (можно изменять только на мастере).



Директории с настройками и данными

- pg_log логи (можно изменять).
- pg_multixact файлы синхронизации *основной сегмент -> зеркало*.
- pg_stat_tmp временные файлы сборщика статистики.
- pg_subtrans служебная информация о транзакциях.
- pg_tblspc символьные ссылки на tablespaces (не используется).
- pg_twophase файлы синхронизации *основной сегмент -> зеркало*.
- pg_utilitymodedtmredo служебная директория для redo в служебном режиме.
- PG VERSION актуальная версия PG.
- pg_xlog журнал транзакций.
- plcontainer_configuration.xml конфигурация расширения PL/Container.
- postgresql.conf настройки БД (не рекомендуется менять напрямую).
- postmaster.opts опции, с которыми был запущен процесс БД.
- postmaster.pid PID процесса БД и дополнительная информация.



Процессы: Мастер

- /usr/lib/gpdb/bin/postgres -D /data1/master/gpseg-1 -p 5432 -E
- /usr/lib/gpdb/bin/gpmmon -D /data1/master/gpseg-1/gpperfmon/conf/gpperfmon.conf -p 5432
- /usr/lib/gpdb/bin/gpsmon -m 0 -t 150 -l /data1/master/gpseg-1/gpperfmon/logs -v 0 8888

Каждый запрос порождает процесс следующего вида:

postgres: 5432, gpadmin adb [local] con748725 seg-1 cmd9 slice1 MPPEXEC INSERT

По con[0-9] (это session_id) можно связать процесс на мастере с процессами на сегментах.



Процессы: Сегменты

- /usr/lib/gpdb/bin/postgres -D /data1/mirror/gpseg3 -p 10501
- /usr/lib/gpdb/bin/gpsmon -m 0 -t 150 -l /data2/primary/gpseg5/gpperfmon -v 0 8888

Каждый запрос порождает процесс следующего вида:

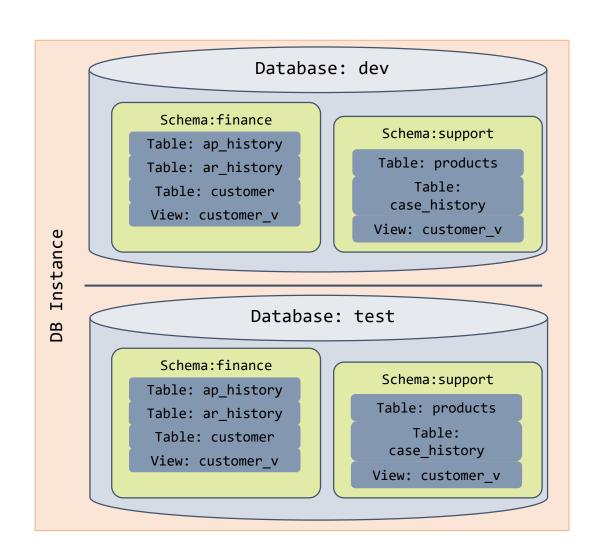
postgres: 40001, gpadmin adb 192.168.100.13(19273) con748725 seg1 cmd9 MPPEXEC INSERT



Иерархия

Уровни:

- База Данных:
 - Несколько БД в одной СУБД.
 - Перенос данных между БД невозможен.
 - БД разделены физически.
- Схема:
 - Логическое объединение сущностей внутри БД.
- Объект:
 - Таблица, представление, функция, т.д..
- Имя объекта:
 - ASCII standard: database.schema.object
 - Но лучше: schema.object





Шаблоны

- При инициализации СУБД создаётся три БД-шаблона:
 - postgres.
 - template0.
 - template1.
- CREATE DATABASE копирует template1 со всеми объектами.
- He следует изменять template0, это шаблон пустой БД, используемый утилитой gprestore.



Схемы по умолчанию

В ADB создаются автоматически схемы:

- arenadata_toolkit настройки и информация о распределении таблиц и выполненных операциях.
- gp_toolkit информация о размерах таблиц, раздувании таблиц, индексах, логах, ресурсных группах, спиллфайлах.
- information_schema информация об объектах БД согласно стандарту ANSI SQL 2008.
- pg_aoseg служебная схема информации АО-таблиц.
- pg_bitmapindex служебная схема информации bitmap-индексов.
- pg_catalog полная информация о БД и её объектах.
- pg_toast служебная схема информации хранилища toast.
- public схема для данных, доступная всем пользователям.



Поисковый путь

- Полное наименование объекта состоит из явно указанной схемы и имени объекта: <схема.имя>.
- Если не указать схему, то системе нужно понять, в какой схеме искать или создавать объект.
- Определяется схема с помощью пути поиска, который задается в переменной search_path.
- В параметре search_path можно через запятую перечислить схемы, в которых система будет искать объект, если схема в запросе не была указана явно.
- Несуществующие схемы и схемы, на которые отсутствуют права доступа, будут пропускаться.
- Схема pg_catalog включается по умолчанию, даже если не указана.
- При создании нового объекта, он будет помещаться в первую указанную в search_path схему.
- Проверить текущее значение переменной можно запросом SHOW search_path;
- Реальное значение search_path показывает функция current_schemas(): SELECT current_schemas(true);



Полезные объекты в системных схемах

• pg_catalog.pg_class – справочник всех объектов в БД. Содержит OID – системный идентификатор объекта (как и большинство системных таблиц).

```
adb=# select oid,relname, relnamespace, relstorage, relpersistence, reltuples from pg_class where relname
='pg_class';
oid | relname | relnamespace | relstorage | relpersistence | reltuples
1259 | pg class | 11 | h | p | 520
```

Relstorage: a - row-oriented append-optimized, c- column-oriented, h - heap, v - представление, m - матвью, x - внешняя таблица. Relpersistence: p - обычная таблица, u - unlogged временная таблица, t — простая временная таблица

• Information_schema.tables, information_schema.schemata — то же самое, но меньше информации и согласовано с ANSI SQL 2008.



Полезные объекты в системных схемах

- pg_catalog.gp_segment_configuration информация о статусе сегментов, зеркал и мастеров:
 - dbid уникальный id инстанса (разный у праймари и зеркала). Целое число, отсчёт с 1.
 - content уникальный id шарда данных (одинаковый у праймари и зеркала). Целое число, отсчет с -1.
 - role текущая роль сегмента. Варианты: p основной сегмент, m зеркало.
 - preferred_role изначальная роль сегмента. Варианты: p основной сегмент, m зеркало.
 - mode статус синхронизации основного сегмента с зеркалом. Варианты: s норма, n нет синхронизации.
 - status отвечает ли сегмент на запросы мастера. Варианты: u отвечает, d недоступен.
 - datadir физическое расположение рабочих директорий на сегменте и мастере.
 - port порт сегмента.
 - hostname имя сервера.
 - address адрес сервера.
- pg_catalog.gp_configuration_history историческая информация с описанием событий. Заглядывайте сюда при сбоях – важно выявить первый произошедший отказ.



Полезные объекты в системных схемах

pg_catalog.pg_stat_activity – текущие сессии СУБД:

- pg_catalog.pg_settings все настройки СУБД.
- gp_toolkit.gp_log_database внешняя таблица с логами СУБД на всех сегментах и мастере. Могут быть проблемы с кодировкой и производительностью.
- gp_toolkit.gp_resgroup_status детальная информация о ресурсных группах.



Лабораторная. Служебные объекты ADB

- 1. Выясните с помощью одного SQL-запроса, на каком сервере располагается зеркало сегмента с dbid=2.
- 2. Выясните, сколько внешних таблиц содержится в БД.
- 3. Выясните, в какой схеме находится таблица stg clients rnd.





Корпоративная платформа хранения и обработки больших данных

Ролевая модель



Ролевая модель

Ролевая модель построена на использовании универсального объекта ROLE:

- Роль сущность в СУБД, которая может владеть объектами и иметь привилегии.
- Доступна иерархия. Объект ROLE может быть пользователем или группой.
- Роли могут включаться в другие роли, наследуя их привилегии (по-умолчанию).
- Для удобства пользовательские роли создаются с опцией LOGIN (возможность входа), а группы без.
- Роли глобальны для всех БД внутри СУБД.
- Существует базовая роль public, в которую автоматически включаются все созданные роли. От неё наследуется право работать со схемой public.



```
CREATE ROLE name [[WITH]
      SUPERUSER | NOSUPERUSER - будет ли обладать роль правами администратора (доп. привелегии)
     CREATEDB | NOCREATEDB
     CREATEROLE | NOCREATEROLE
     CREATEUSER | NOCREATEUSER
     CREATEEXTTABLE | NOCREATEEXTTABLE
      [ ( attribute='value'[, ...] ) ]
           where attributes and value are:
           type='readable'|'writable'
           protocol='gpfdist'|'http'|'pxf'|'s3'
      INHERIT | NOINHERIT
     LOGIN | NOLOGIN
     REPLICATION | NOREPLICATION
```



```
CREATE ROLE name [[WITH]
     SUPERUSER | NOSUPERUSER
     CREATEDB | NOCREATEDB - может ли создавать базы
     CREATEROLE | NOCREATEROLE
     CREATEUSER | NOCREATEUSER
     CREATEEXTTABLE | NOCREATEEXTTABLE
      [ ( attribute='value'[, ...] ) ]
           where attributes and value are:
           type='readable'|'writable'
           protocol='gpfdist'|'http'|'pxf'|'s3'
      INHERIT | NOINHERIT
     LOGIN | NOLOGIN
     REPLICATION | NOREPLICATION
```



```
CREATE ROLE name [[WITH]
      SUPERUSER | NOSUPERUSER
     CREATEDB | NOCREATEDB
     CREATEROLE | NOCREATEROLE - может ли создавать роли
     CREATEUSER | NOCREATEUSER - устаревшее, осталось для совместимости
     CREATEEXTTABLE | NOCREATEEXTTABLE
      [ ( attribute='value'[, ...] ) ]
           where attributes and value are:
           type='readable'|'writable'
           protocol='gpfdist'|'http'|'pxf'|'s3'
      INHERIT | NOINHERIT
     LOGIN | NOLOGIN
     REPLICATION | NOREPLICATION
```



```
CREATE ROLE name [[WITH]
     SUPERUSER | NOSUPERUSER
     CREATEDB | NOCREATEDB
     CREATEROLE | NOCREATEROLE
     CREATEUSER | NOCREATEUSER
     CREATEEXTTABLE | NOCREATEEXTTABLE - может ли создавать внешние таблицы
      [ ( attribute='value'[, ...] ) ] - и какие именно
           варианты опций:
           type='readable'|'writable'
           protocol='gpfdist'|'http'|'pxf'|'s3'
      INHERIT | NOINHERIT
     LOGIN | NOLOGIN
     REPLICATION | NOREPLICATION
```



```
CREATE ROLE name [[WITH]
      SUPERUSER | NOSUPERUSER
     CREATEDB | NOCREATEDB
     CREATEROLE | NOCREATEROLE
     CREATEUSER | NOCREATEUSER
     CREATEEXTTABLE | NOCREATEEXTTABLE
      [ ( attribute='value'[, ...] ) ]
           where attributes and value are:
           type='readable'|'writable'
           protocol='gpfdist'|'http'|'pxf'|'s3'
     INHERIT | NOINHERIT - наследование
     LOGIN | NOLOGIN - возможность входа
     REPLICATION | NOREPLICATION - полномочия по репликации
```



```
CONNECTION LIMIT connlimit - лимит подключений
 [ ENCRYPTED | UNENCRYPTED ] PASSWORD 'password' - пароль
VALID UNTIL 'timestamp' - устаревание пароля
| [ DENY deny_point ] | [ DENY BETWEEN deny_point AND deny_point] - ограничение по входу
 SYSID uid [, ...]
 RESOURCE QUEUE queue_name
 RESOURCE GROUP group_name
 IN ROLE rolename [, ...]
 ROLE rolename [, ...]
 ADMIN rolename [, ...]
```



```
CONNECTION LIMIT connlimit
 [ ENCRYPTED | UNENCRYPTED ] PASSWORD 'password'
 VALID UNTIL 'timestamp'
| [ DENY deny_point ] | [ DENY BETWEEN deny_point AND deny_point]
 SYSID uid [, ...]
 RESOURCE QUEUE queue_name - устаревшее, оставлено для совместимости
 RESOURCE GROUP group_name - привязать роль к ресурсной группе
 IN ROLE rolename [, ...]
 ROLE rolename [, ...]
 ADMIN rolename [, ...]
```



```
CONNECTION LIMIT connlimit
[ ENCRYPTED | UNENCRYPTED ] PASSWORD 'password'
 VALID UNTIL 'timestamp'
| [ DENY deny_point ] | [ DENY BETWEEN deny_point AND deny_point]
 SYSID uid [, ...]
 RESOURCE QUEUE queue_name
 RESOURCE GROUP group name
 IN ROLE rolename [, ...] - включить создаваемую роль в указанные роли как в группы
 ROLE rolename [, ...]
 ADMIN rolename [, ...]
```



```
CONNECTION LIMIT connlimit
[ ENCRYPTED | UNENCRYPTED ] PASSWORD 'password'
 VALID UNTIL 'timestamp'
| [ DENY deny_point ] | [ DENY BETWEEN deny_point AND deny_point]
 SYSID uid [, ...]
 RESOURCE QUEUE queue_name
 RESOURCE GROUP group_name
 IN ROLE rolename [, ...]
 ROLE rolename [, ...] - включить указанные роли в создаваемую как членов группы
 ADMIN rolename [, ...] - то же самое, но с расширенными полномочиями
```



Изменение роли

Смена имени: ALTER ROLE name RENAME TO newname; Смена параметра конфигурации СУБД: ALTER ROLE name SET config_parameter {TO | =} {value | DEFAULT}; Сброс параметра конфигурации СУБД: ALTER ROLE name RESET config parameter; Привязка к ресурсной группе: ALTER ROLE name RESOURCE GROUP {group_name | NONE};

Модификация опций роли (примечание: связи с другими ролями или объектами так изменить не получится): ALTER ROLE name [[WITH] option [...]];

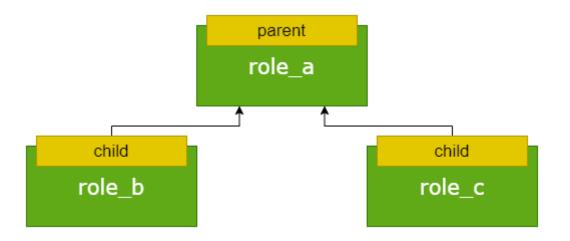


Установка иерархии после создания роли

Для включения ролей в группы используется команда GRANT:

```
GRANT parent_role [, ...] TO member_role [, ...] [WITH ADMIN OPTION]
```

GRANT role_a TO role_b, role_c;



Для удаления связи используется команда REVOKE:

```
REVOKE [ADMIN OPTION FOR] parent_role [, ...] FROM member_role [, ...] [CASCADE | RESTRICT]
```



Выдача полномочий. Таблица

Полномочия выдаются той же командой GRANT и отзываются при помощи REVOKE. Доступны:



Выдача полномочий. База и схема

Для доступа к таблице обязательно необходимо иметь доступ к базе и схеме, в которых она лежит:

CXEMA:
 GRANT { {CREATE | USAGE} [,...] | ALL [PRIVILEGES] }
 ON SCHEMA schemaname [, ...]
 TO {rolename | PUBLIC} [, ...] [WITH GRANT OPTION]
 БД:
 GRANT { {CREATE | CONNECT | TEMPORARY | TEMP} [,...] | ALL [PRIVILEGES] }
 ON DATABASE dbname [, ...]
 TO {rolename | PUBLIC} [, ...] [WITH GRANT OPTION]



Выдача полномочий. Другие полномочия

• Последовательности: GRANT { {USAGE | SELECT | UPDATE} [,...] | ALL [PRIVILEGES] } ON SEQUENCE sequencename ... • Функции: GRANT { EXECUTE | ALL [PRIVILEGES] } ON FUNCTION funchame ([[argmode] [argname] argtype [, ...]])... • Языки для написания функций и безымянных блоков: GRANT { USAGE | ALL [PRIVILEGES] } ON LANGUAGE languame ... • Тейблспейсы: GRANT { CREATE | ALL [PRIVILEGES] } ON TABLESPACE tablespacename ... • Протоколы для внешних таблиц: GRANT { SELECT | INSERT | ALL [PRIVILEGES] } ON PROTOCOL protocolname ...



Отзыв полномочий и удаление роли

Для отзыва полномочий используется команда REVOKE:

• Отзыв связей в структуре ролей:

```
REVOKE [ADMIN OPTION FOR] parent_role [, ...] FROM member_role [, ...] [CASCADE | RESTRICT]
```

• Отзыв полномочий на использование таблицы:

```
REVOKE [GRANT OPTION FOR] { {SELECT | INSERT | UPDATE | DELETE | REFERENCES | TRIGGER | TRUNCATE } [, ...] | ALL [PRIVILEGES] } ON { [TABLE] table_name [, ...] | ALL TABLES IN SCHEMA schema_name [, ...] } FROM { [ GROUP ] role_name | PUBLIC} [, ...] [CASCADE | RESTRICT]
```

• Отзыв полномочий на администрирование групповой роли:

```
REVOKE [ADMIN OPTION FOR] parent_role [, ...] FROM [ GROUP ] member_role [, ...] [CASCADE | RESTRICT]
```



Доступ к СУБД

Помимо роли с параметром LOGIN, пользователю необходимо для подключения к СУДБ иметь запись в файле pg_hba.conf на мастер-сервере. Этот файл отвечает за проверку параметров коннекта. На сегментах править этот файл не следует.

Внутри файла текстовые строки для описания локалных и удаленных подключений:

- host database role address authentication-method
- local database role authentication-method

Добавить всех пользователей группы можно указав имя роли с плюсом: +group_name.

Добавить всех пользователей из отдельного файла: @filename.

Адрес указывается с подсетью: 172.20.143.0/24.

Можно указать 0.0.0.0/0 для коннектов с любого адреса.



Лабораторная. Создание ролей

- 1. Создайте суперпользователя adb_super с правами входа в систему, ресурсной группой admin_group и паролем "superpassword".
- 2. Создайте группу adb_group без прав входа в систему.
- 3. Создайте пользователя adb_1 с правом входа в систему добавьте его в группу adb_group.
- 4. Создайте пользователя adb_2 с правом входа в систему.
- 5. Добавьте пользователя adb_2 в группу adb_group.
- 6. Дайте полные права на протокол РХF группе adb_group.
- 7. Дайте права на чтение таблицы arenadata_toolkit.db_files_current группе adb_group.
- 8. Смените пароль пользователю adb_1 на "password 1".





Корпоративная платформа хранения и обработки больших данных

Ресурсные группы



Ресурсные группы

- Resource queue ресурсные очереди старый механизм (до версии 5.3).
- **Resource groups** ресурсные группы (РГ) новый механизм (начиная с версии 5.3):
 - РГ набор ограничений, накладываемых на роли (пользователей).
 - Используют Linux Control Groups (cgroups) и vmtracker.
 - Также позволяют контролировать внешние компоненты (например, PL/Container).



Параметры ресурсных групп

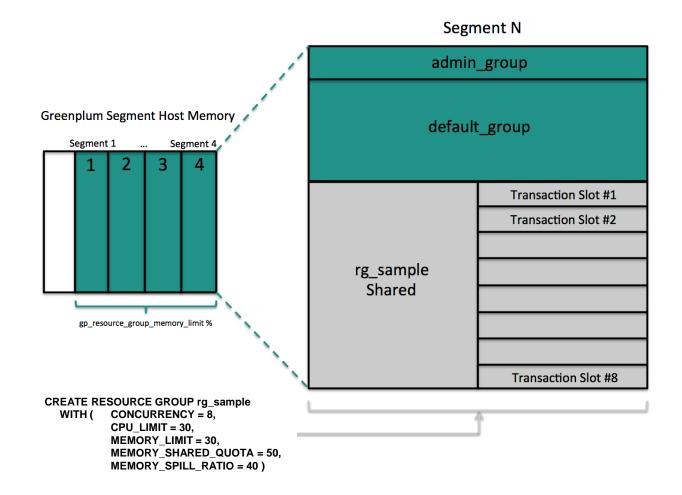
Атрибут	Описание	Значение по умолчанию
MEMORY_AUDITOR	Vmtracker – для управления ролями СУБД; Cgroups – для управления внешними компонентами	vmtracker
CONCURRENCY	Число параллельных транзакций (включая IDLE). Можно обойти с помощью gp_resource_group_bypass=true, но при этом запросу доступно только 10 MB RAM	20
CPU_RATE_LIMIT	Процент CPU кластера, доступный PГ. Сумма параметров всех PГ должна быть <=100. Общее количество CPU задаётся gp_resource_group_cpu_limit . Не совместим с CPUSET . Выделение гибкое – пока есть свободные ресурсы, будут выдаваться всем	-
CPUSET	Перечень ядер, зарезервированных под данную РГ. Запросы РГ будут утилизировать только данные ядра. Не совместим с CPU_RATE_LIMIT. Если данная РГ не использует ядра, они будут простаивать. Не используйте ядро 0. Формат: '1,3-4'	-
MEMORY_LIMIT	Процент RAM кластера, доступный РГ. Сумма параметров всех РГ должна быть <=100. Общее количество памяти задаётся gp_resource_group_memory_limit . Выделение гибкое – пока есть свободные ресурсы, будут выдаваться всем	0
TA	Процент RAM PГ, который будет доступен всем транзакциям PГ. (100-MEMORY_SHARED_QUOTA)/CONCURRENCY – будет гарантировано каждой транзакции в PГ	80
MEMORY_SPILL_RATIO	Процент RAM, по достижении которого запрос спилит данные на диск. Можно задавать в сессии параметром memory_spill_ratio. Параметр влияет на начальное выделение памяти. Малое значение может ускорить простые запросы. Если memory_spill_ratio = 0, то для выделения первоначальной памяти используется значение параметра statement_mem.	0

Нюансы

- **gp_resource_group_cpu_limit** по умолчанию задаётся 0.9. Если у вас есть другие критичные ресурсоёмкие приложения на кластере, уменьшите значение;
- **gp_resource_group_memory_limit** по умолчанию задаётся 0.7. Если у вас есть другие критичные ресурсоёмкие приложения на кластере, уменьшите значение. Выбирайте параметр, исходя из стратегии зеркалирования.
- Оставляйте 10-20% памяти неаллоцированной для непредсказуемых запросов.
- СУБД опирается на статистику при подсчёте необходимого количества памяти (однако, также считает и актуальное использование).
- При превышении concurrency запрос будет поставлен в очередь.
- Используйте gp_toolkit.gp_resgroup_config, gp_toolkit.gp_resgroup_status, gp_toolkit.gp_resgroup_status_per_host и gp_toolkit.gp_resgroup_status_per_segment для контроля потребления ресурсов.



Распределение памяти





Создание ресурсной группы

```
CREATE RESOURCE GROUP name WITH (
        CPU_RATE_LIMIT=integer | CPUSET=tuple
        MEMORY_LIMIT=integer
        [ CONCURRENCY=integer ]
        [ MEMORY_SHARED_QUOTA=integer ]
        [ MEMORY_SPILL_RATIO=integer ]
        [ MEMORY_AUDITOR= {vmtracker | cgroup} ]
ALTER RESOURCE GROUP name SET group_attribute value
ALTER ROLE name RESOURCE GROUP {group_name | NONE}
```





Корпоративная платформа хранения и обработки больших данных

Расширение Diskquota



Diskquota



- **diskquota** модуль, который позволяет ограничить используемое место на дисках для схем и ролей.
- Квота на уровне схем: устанавливает лимит на размер для всех таблиц принадлежащих конкретной схеме.
- Квота на уровне ролей: устанавливает лимит на размер для всех таблиц владельцем которых является конкретная роль.
- Устанавливается в виде расширения и использует отдельную базу данных с именем «diskquota».
- В дистрибутиве ADB, расширение устанавливается опционально с помощью ADCM.



Использование расширения

• Если расширение **diskquota** было добавлено после того, как в СУБД уже были данные, то необходимо выполнить первоначальную инициализацию модуля для каждой БД:

```
SELECT diskquota.init_table_size_table();
```

Для установки квоты на уровне схем используется функция diskquota.set_schema_quota():
 SELECT diskquota.set_schema_quota('stg', '250GB');

• Для установки квоты на уровне ролей используется функция diskquota.set_role_quota(): SELECT diskquota.set_role_quota('test_user', '500GB');

• Для снятия квоты на уровне ролей или схем используются функции diskquota.set_role_quota() и diskquota.set_schema_quota() с параметром «-1»:

```
SELECT diskquota.set_schema_quota('stg', '-1');
SELECT diskquota.set_role_quota('test_user', '-1');
```



Нюансы

- Кол-во доступных баз данных для включения дисковых квот не больше 10.
- Для каждой базы данных создаётся дополнительный процесс на мастер-сервере.
- Используемое место это размер таблиц на всех сегментах, включая индексы и служебные таблицы.
- Частота обновления данных по дисковым квотам зависит от значения параметра diskquota.naptime.
- В некоторых случаях квота может быть превышена.
- Для просмотра установленных квот используйте представления diskquota.show_fast_schema_quota_view и diskquota.show_fast_role_quota_view.
- diskquota-модуль не учитывает размер таблиц, которые были созданы внутри ещё не закомиченной транзакции или с помощью команды CREATE TABLE AS.



Конец первой части

